

# 基于长短期记忆神经网络的遥感数据预测海表下温盐结构

杨一洲

## 摘要

卫星遥感可以大尺度地探测和预测海洋表层下的温度和盐度结构。在海洋大数据时代，如何充分利用多源卫星观测来准确探测和预测全球海洋表层下温盐结构，推进我们对海洋内部过程的理解是极具挑战性的。本研究提出了一种新的基于深度学习的方法——双向长短期记忆（Bi-LSTM）神经网络，结合表面遥感观测（海面温度异常、海面温度高度异常、海面盐度异常、海面经纬度信息）和 Argo 网格数据，预测全球海洋表层下温度和盐度异常。由于海洋动态参数的时间依赖性和周期性，Bi-LSTM 考虑海洋变化的显著时间特征，擅长于时间序列特征学习，可以很好地提高预测的鲁棒性和泛化能力。以 2015 年 12 月为例，平均总体决定系数预测结果是 0.691（STA）和 0.392（SSA），平均归一化均方根误差为 0.039（STA）和 0.051（SSA）。将该模型应用于 2010 年和 2015 年不同月份的双向预测，以证明该模型的适用性和鲁棒性。本研究表明，Bi-LSTM 在预测地下和深海温度和盐度结构方面更具优势，充分考虑了全球海洋数据的时间依赖性。

**关键词：**海表层下温盐异常；表层遥感观测；遥感预测；双向长短期记忆

## 1 引言

海洋在稳定气候方面起着决定性的作用，它通过物质和能量的传输和交换调节和稳定气候。地球热量超过 93% 储存在海洋中，地球能量失衡（EEI）导致近几十年来海洋显著变暖<sup>[1][2]</sup>。海下温度和盐度是理解海洋的气候变化所必需的两个基本变量。在最近的全球变暖期间，全球海洋通过热的吸收和储存而显著变暖。近几十年来，海洋热含量显著增加<sup>[3][4][5][6]</sup>。Boyer 等人<sup>[7]</sup>表明，从 1993 年至 2008 年，全球上层海洋显著变暖。近年来，300m 以下的深海吸热速率进一步增加<sup>[3][8][9][10]</sup>。海洋系统加速了热吸收，从而导致全球海洋迅速变暖。海洋热含量在 2019 年达到历史新高<sup>[6]</sup>。

另一方面，海洋盐度对海洋变暖的研究也很重要。先前的一项研究提出了盐度机制来解释变暖信号是如何从上层海洋扩散到中间海洋的<sup>[11]</sup>，这说明了盐度分布对海洋变暖演化的重要作用。此外，海洋盐度调节全球水文循环<sup>[12]</sup>。海洋温度和盐度也与热盐碱的扩张有关，进而导致海平面上升<sup>[13]</sup>。因此，预测海下温度和盐度结构对于提高我们对海洋表层下过程和变化的理解至关重要<sup>[14]</sup>。

但是由于现场数据的缺乏，海洋内部机制和过程的研究受到极大限制，导致了海洋变暖分析和预测的不确定性<sup>[15][16][17]</sup>。在 Argo 时代（自 2004 年以来），除了高纬度地区外，Argo 已经对全球 0 至 2000 米的海洋进行了持续的观测。然而，在 Argo 时代之前，数据是有限的。卫星遥感已经提供了具有高时空分辨率和长期序列的多源海面观测数据，但所有这些观测都仅限于海面<sup>[18]</sup>。

## 2 相关工作

以往的研究表明，深层海洋遥感（DORS）技术结合浮标数据具有从卫星观测中间接预测海洋内部参数的巨大潜力<sup>[19][20]</sup>。DORS 方法包括数据同化和数值建模<sup>[21]</sup>、动态理论方法<sup>[22][23][24]</sup>和经验统计方法<sup>[19][25]</sup>。由于数值建模和动态理论建模的复杂性和不确定性，不能保证其对大规模海洋表层下建

模的预测的精度。2000 年 Meinen 和 Watts<sup>[26]</sup>结合了历史水文和声学旅行时间，获得了横跨北大西洋洋流的横断面上的垂直结构。2009 年 Takano 等人<sup>[27]</sup>使用了一个带有一组参数的两层模型根据经验来估计中尺度三维海洋温度结构。2011 年 Meijers 等人<sup>[28]</sup>提出了一种经验模式映射，利用卫星测高法来估计南大洋的四维结构。

但在海洋大数据时代，数据驱动模型具有良好的性能，可以在 DORS 应用中实现较高的精度，特别是基于机器学习的模型。经验统计模型已经完善，包括线性回归模型<sup>[29][30][31][32][25]</sup>，基于经验的正交函数的方法<sup>[33][34]</sup>，地理加权回归模型<sup>[20]</sup>，以及人工神经网络<sup>[18]</sup>，自组织映射<sup>[35][36][37]</sup>，支持向量机<sup>[38][19]</sup>、随机森林<sup>[20]</sup>、聚类神经网络<sup>[14]</sup>和 XGBoost<sup>[39]</sup>。

虽然经典的机器学习算法对 DORS 的研究做出了巨大的贡献，但它们不能考虑到海洋数据的时空特征。深度学习算法在克服限制和提高性能方面具有巨大的潜力。例如，长短期记忆（LSTM）捕获数据的时间序列信息，实现时间序列学习，卷积神经网络考虑数据的空间特征，实现空间学习。深度学习已经在许多其他领域得到了很好的应用，但在地球科学领域仍处于起步阶段<sup>[40]</sup>，随着海洋观测数据的积累，它在 DORS 领域显示出了巨大的潜力。

虽然一些研究在海洋遥感中使用了深度学习算法，但它们并没有将这些方法扩展到大规模海洋<sup>[41][42]</sup>。海洋数据呈现出固有的空间非线性和时间依赖性<sup>[37][43][44]</sup>，深度学习算法双向长短期记忆（Bi-LSTM）具有强大的能力，能够掌握这些非线性和时间依赖的特征，并做出准确的预测。该方法可以在时间和空间上得到推广，并可以重建时间序列的海洋表层下参数，从而推导出其他关键的海洋变量，如流量、涡度等。本研究提出了基于深度学习的方法（Bi-LSTM）来建立海洋表层下（0 至 1000 米）温盐异常的时间序列模型。

### 3 本文方法

#### 3.1 本文方法概述

Bi-LSTM 是一种针对 LSTM 的改进算法，如图 1 所示。Bi-LSTM 包含两个单向 LSTM，它们同时前后处理输入序列，从而可以捕获被单向 LSTM 忽略的信息。LSTM 是霍克勒特和施米杜伯在 1997 年提出的一种特殊类型的递归神经网络<sup>[45]</sup>。它适用于时间序列建模，已广泛应用于机器翻译和语音识别领域。LSTM 的主要思想是利用目标变量的历史信息。与经典的前馈神经网络不同，LSTM 中的训练误差在一个时间序列上传播，捕获训练数据中的历史信息的时间依赖关系。LSTM 网络的主要组成部分是忘记门、输入门和输出门。遗忘门控制着有选择性地遗忘细胞中的信息：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

其中  $x_t$  为原始输入， $h_{t-1}$  为最后时刻 LSTM 的输出值， $[h_{t-1}, x_t]$  表示将两个向量拼接成一个较长的向量， $b$  为偏置向量， $W$  为权值矩阵。

输入门决定单元状态向量  $C_t$  如何更新，具体如下：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$

$\tilde{C}_t$  是临时状态向量。然后，我们利用先前时刻的状态向量  $C_{t-1}$  和临时状态向量  $\tilde{C}_t$  的加权求和，得到




图 1: 双向长短期记忆 (Bi-LSTM) 的结构

新的状态向量  $C_t$ 。

输出门负责利用最新的细胞状态向量和  $\tanh$  激活函数更新隐藏状态，得到输出向量  $h_t$ ：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \cdot \tanh(C_t)$$

然后，利用前向传播和反向传播算法作为人工神经网络来优化权值和偏差。隐层上的激活函数使用整流线性单元 (ReLU) 函数，因为 ReLU 不容易导致消失梯度问题。对于优化器，结果表明，Adam 的性能最好，因此采用 Adam 优化器。

为了使 Bi-LSTM 模型获得良好的预测结果，需要为模型选择合适的超参数，从训练数据集中随机选择 20% 的数据集作为 Bi-LSTM 超参数调整的验证数据集。在本研究中，选择了一个 3 层（两个 Bi-LSTM 层和一个全连接层）的神经网络，神经元计数分别为 32、64 和 64。

同时，我们对网络的每个隐藏层进行批处理归一化。Masters 和 Luschi 认为在 2 到 32 之间的批大小可以达到最佳性能<sup>[46]</sup>。因此，我们将批处理大小设置为 32。同时使用均方根误差的损失函数来确定最佳训练轮次。采用均方根误差 (RMSE) 和决定系数 ( $R^2$ ) 来确定 Bi-LSTM 的最佳时间序列长度。结果表明，当时间序列长度为 10 时，该模型具有最好的性能 ( $R^2$  最高，RMSE 最低)。因此，本研究将时间步长设置为 10。

### 3.2 研究区域和数据

研究区域为全球海洋，覆盖  $180^\circ\text{W}$ - $180^\circ\text{E}$  和  $78.375^\circ\text{S}$ - $77.625^\circ\text{N}$ 。本研究中使用的面遥感数据包括海表温度 (SST)、海表高度 (SSH)、海面盐度 (SSS) 以及海面风的北和东分量 (USSW 和 VSSW)。所有海面参数均为 1993 年至 2018 年的每月数据。论文中，海平面异常是由自 1993 年以来的空间分辨率为  $0.25^\circ \times 0.25^\circ$  的卫星高度计 (<http://www.aviso.altimetry.fr>) 获得的。海温是由 1981 年的最佳插值海面温度数据确定的，其空间分辨率为  $0.25^\circ \times 0.25^\circ$  (<https://www.ncdc.noaa.gov/oisst>)。SSS 来自欧洲航天局的土壤湿度和海洋盐度，从 2009 年开始的空间分辨率为  $0.25^\circ \times 0.25^\circ$  (<http://eopi.esa.int>)。SSW 由交叉校准多平台获得，空间分辨率为  $0.25^\circ \times 0.25^\circ$  (<https://rda.ucar.edu/datasets/ds745.1/>)。我们还使用经度 (LON) 和纬度 (LAT) 作为输入参数。海表层下温度 (ST) 和盐度 (SS) 数据来自网格状的

Argo 产品 ([http://apdrc.soest.hawaii.edu/projects/Argo/data/gridded/On\\_standard\\_levels/index-1.html](http://apdrc.soest.hawaii.edu/projects/Argo/data/gridded/On_standard_levels/index-1.html))。本研究采用  $1^{\circ} \times 1^{\circ}$  网格 Argo 上 1000m 数据，以 16 个深度水平作为标记数据。采用最近邻插值的方法，将海面数据统一到  $1^{\circ} \times 1^{\circ}$  的空间分辨率。上述所有遥感变量 (SSH、SST、SSS、USSW、VSSW) 和 Argo 网格数据均需减去其气候学 (2005-2016 年的平均值)，得到其异常值。我们只关注难以捕获的非季节性信号。

## 4 复现细节

### 4.1 与已有开源代码对比

本次复现实验没有参考任何相关源代码。首先需要构建数据集，对输入变量进行均一化处理并统一分辨率以构建训练集。训练集数据既包含目标月份的海表面观测数据，也包含之前月份的对应海表面观测数据，以同时采取海洋近期和远期的变化特征。之后，对研究海域进行 Bi-lstm 模型建模。根据损失函数调整超参数设置并多次进行迭代训练，直至模型的反演结果达到预期。

构建训练数据集同时引入了海洋近期数据信息和历史信息。具体来说，输入变量包括目标月份和前 10 个月份的海表面变量信息，输出变量为目标月份预测的次表层温度异常。本次实验构建的训练集和测试集所包含的输入数据，训练集主要采集了 2012 年至 2015 年时间范围，测试集为 2016 年的 12 个月份。训练模型实现了 Bi-lstm 模型，两个 Bi-LSTM 层和一个全连接层的神经网络神经元计数分别为 32、64 和 64。RMSE 和  $R^2$  计算使用 sklearn 库 metrics 下的 r2\_score 和 mean\_squared\_error 函数。

### 4.2 实验环境搭建

操作系统为 64 位 windows11，开发平台为 pycharm 2022 x64，使用 pycharm 远程服务器功能连接至服务器，服务器 python 环境 3.7，显卡配置 A40，设置生成随机数的种子参数为 0，使用 torch 框架实现实验，torch 版本为 1.13.0+cu117 最新环境，使用 scikit-learn 工具包版本 1.02。

## 5 实验结果分析

本部分对实验所得结果进行分析，实验结果如图 2 和 3 所示，论文结果左，复现实验结果右。

决定系数  $R^2$  来看在 0 至 250m 效果复现较好，效果基本一致，250 至 1000m 复现结果不如论文结果。

NRMSE 结果来看，复现 0 至 800m 的 NRMSE 远不如论文效果，只有 800 至 1000m 的 NRMSE 接近论文。

总体看论文误差都在 0.0 几的误差，而复现结果误差量级在 0.1，不及论文水平，预测可能是所用的实验数据和训练所选取的范围有差别造成的影响。

## 6 总结与展望

本研究基于卫星遥感数据的深度学习算法 Bi-LSTM，提出了一种反演全球 1000 米以上地表温度盐度异常的新应用。时间序列 STA 采用海面遥感观测数据 (地表高度、地表温度、地表盐度和地表风) 结合空间信息 (经度和纬度)，Argo 数据用于训练和准确性评价。结果表明，使用时间序列 Bi-LSTM 模型预测 STA，考虑更多的输入变量有利于网络性能。应用 Bi-LSTM 模型对不同月份的 STA 进行了预测，结果表明，Bi-LSTM 模型具有较强的鲁棒性和泛化能力，在地下温度盐度结构的时间序列预测




图 2: 实验结果决定系数与论文结果对比




图 3: 实验结果归一化均方根误差与论文结果对比

方面具有很大的潜力。下一步的工作进展将在日尺度的温度盐度反演应用展开。

## 参考文献

- [1] MEYSSIGNAC B, BOYER T, ZHAO Z, et al. Measuring global ocean heat content to estimate the Earth energy imbalance[J]. *Frontiers in Marine Science*, 2019, 6: 432.
- [2] JOHNSON G C, LYMAN J M. Warming trends increasingly dominate global ocean[J]. *Nature Climate Change*, 2020, 10(8): 757-761.
- [3] BALMASEDA M A, TRENBERTH K E, KÄLLÉN E. Distinctive climate signals in reanalysis of global ocean heat content[J]. *Geophysical Research Letters*, 2013, 40(9): 1754-1759.
- [4] CHENG L, ZHU J. 2017 was the warmest year on record for the global ocean[Z]. 2018.
- [5] CHENG L, ZHU J, ABRAHAM J, et al. 2018 continues record global ocean warming[Z]. 2019.
- [6] CHENG L, ABRAHAM J, ZHU J, et al. Record-setting ocean warmth continued in 2019[Z]. 2020.

- [7] BOYER T, DOMINGUES C M, GOOD S A, et al. Sensitivity of global upper-ocean heat content estimates to mapping methods, XBT bias corrections, and baseline climatologies[J]. *Journal of Climate*, 2016, 29(13): 4817-4842.
- [8] MEEHL G A, ARBLASTER J M, FASULLO J T, et al. Model-based evidence of deep-ocean heat uptake during surface-temperature hiatus periods[J]. *Nature Climate Change*, 2011, 1(7): 360-364.
- [9] CHENG L, TRENBERTH K E, FASULLO J, et al. Improved estimates of ocean heat content from 1960 to 2015[J]. *Science Advances*, 2017, 3(3): e1601545.
- [10] ALLISON L, ROBERTS C, PALMER M, et al. Towards quantifying uncertainty in ocean heat content changes using synthetic profiles[J]. *Environmental Research Letters*, 2019, 14(8): 084037.
- [11] CHEN X, TUNG K K. Varying planetary heat sink led to global-warming slowdown and acceleration [J]. *Science*, 2014, 345(6199): 897-903.
- [12] BAO S, ZHANG R, WANG H, et al. Salinity profile estimation in the Pacific Ocean from satellite surface salinity observations[J]. *Journal of Atmospheric and Oceanic Technology*, 2019, 36(1): 53-68.
- [13] WOUTERS B, van de WAL R, et al. Global sea-level budget 1993–present[J]. *Earth System Science Data*, 2018, 10(3): 1551-1590.
- [14] LU W, SU H, YANG X, et al. Subsurface temperature estimation from remote sensing data using a clustering-neural network method[J]. *Remote Sensing of Environment*, 2019, 229: 213-222.
- [15] CHENG L, ZHU J. Uncertainties of the ocean heat content estimation induced by insufficient vertical resolution of historical ocean subsurface observations[J]. *Journal of Atmospheric and Oceanic Technology*, 2014, 31(6): 1383-1396.
- [16] WANG G, CHENG L, ABRAHAM J, et al. Consensuses and discrepancies of basin-scale ocean heat content changes in different ocean analyses[J]. *Climate dynamics*, 2018, 50(7): 2471-2487.
- [17] SU H, WU X, LU W, et al. Inconsistent subsurface and deeper ocean warming signals during recent global warming and hiatus[J]. *Journal of Geophysical Research: Oceans*, 2017, 122(10): 8182-8195.
- [18] ALI M, SWAIN D, WELLER R. Estimation of ocean subsurface thermal structure from surface parameters: A neural network approach[J]. *Geophysical Research Letters*, 2004, 31(20).
- [19] SU H, WU X, YAN X H, et al. Estimation of subsurface temperature anomaly in the Indian Ocean during recent global surface warming hiatus from satellite measurements: A support vector machine approach [J]. *Remote Sensing of Environment*, 2015, 160: 63-71.
- [20] SU H, LI W, YAN X H. Retrieving temperature anomaly in the global subsurface and deeper ocean from satellite observations[J]. *Journal of Geophysical Research: Oceans*, 2018, 123(1): 399-410.
- [21] KLEMAS V, YAN X H. Subsurface and deeper ocean remote sensing from satellites: An overview and new results[J]. *Progress in oceanography*, 2014, 122: 1-9.

- [22] WANG J, FLIERL G R, LACASCE J H, et al. Reconstructing the ocean's interior from surface data[J]. *Journal of Physical Oceanography*, 2013, 43(8): 1611-1626.
- [23] LIU L, XUE H, SASAKI H. Reconstructing the ocean interior from high-resolution sea surface information[J]. *Journal of Physical Oceanography*, 2019, 49(12): 3245-3262.
- [24] YAN H, WANG H, ZHANG R, et al. A dynamical-statistical approach to retrieve the ocean interior structure from surface data: SQG-mEOF-R[J]. *Journal of Geophysical Research: Oceans*, 2020, 125(2): e2019JC015840.
- [25] JEONG Y, HWANG J, PARK J, et al. Reconstructed 3-D ocean temperature derived from remotely sensed sea surface measurements for mixed layer depth analysis[J]. *Remote Sensing*, 2019, 11(24): 3018.
- [26] MEINEN C S, WATTS D R. Vertical structure and transport on a transect across the North Atlantic Current near 42 N: Time series and mean[J]. *Journal of Geophysical Research: Oceans*, 2000, 105(C9): 21869-21891.
- [27] TAKANO A, YAMAZAKI H, NAGAI T, et al. A method to estimate three-dimensional thermal structure from satellite altimetry data[J]. *Journal of atmospheric and oceanic technology*, 2009, 26(12): 2655-2664.
- [28] MEIJERS A, BINDOFF N, RINTOUL S. Estimating the four-dimensional structure of the Southern Ocean using satellite altimetry[J]. *Journal of Atmospheric and Oceanic Technology*, 2011, 28(4): 548-568.
- [29] CARNES M R, TEAGUE W J, MITCHELL J L. Inference of subsurface thermohaline structure from fields measurable by satellite[J]. *Journal of Atmospheric and Oceanic Technology*, 1994, 11(2): 551-566.
- [30] BARRON C. The Modular Ocean Data Assimilation System (MODAS) Synthetic Ocean Environment [C]//AGU Spring Meeting Abstracts: vol. 2005. 2005: OS43A-12.
- [31] NARDELLI B B, SANTOLERI R. Reconstructing synthetic profiles from surface data[J]. *Journal of Atmospheric and Oceanic Technology*, 2004, 21(4): 693-703.
- [32] GUINEHUT S, DHOMPS A L, LARNICOL G, et al. High resolution 3-D temperature and salinity fields derived from in situ and satellite observations[J]. *Ocean Science*, 2012, 8(5): 845-857.
- [33] MAES C, BEHRINGER D, REYNOLDS R W, et al. Retrospective analysis of the salinity variability in the western tropical Pacific Ocean using an indirect minimization approach[J]. *Journal of Atmospheric and oceanic technology*, 2000, 17(4): 512-524.
- [34] NARDELLI B B, SANTOLERI R. Methods for the reconstruction of vertical profiles from surface data: Multivariate analyses, residual GEM, and variable temporal signals in the North Pacific Ocean[J]. *Journal of Atmospheric and Oceanic Technology*, 2005, 22(11): 1762-1781.
- [35] WU X, YAN X H, JO Y H, et al. Estimation of subsurface temperature anomaly in the North Atlantic

- using a self-organizing map neural network[J]. *Journal of Atmospheric and Oceanic Technology*, 2012, 29(11): 1675-1688.
- [36] CHEN C, YANG K, MA Y, et al. Reconstructing the subsurface temperature field by using sea surface data through self-organizing map method[J]. *IEEE Geoscience and Remote Sensing Letters*, 2018, 15(12): 1812-1816.
- [37] CHAPMAN C, CHARANTONIS A A. Reconstruction of subsurface velocities from satellite observations using iterative self-organizing maps[J]. *IEEE Geoscience and Remote Sensing Letters*, 2017, 14(5): 617-620.
- [38] LI W, SU H, WANG X, et al. Estimation of global subsurface temperature anomaly based on multisource satellite observations[J]. *J. Remote Sens*, 2017, 21: 881-891.
- [39] SU H, YANG X, LU W, et al. Estimating subsurface thermohaline structure of the global ocean using surface remote sensing observations[J]. *Remote Sensing*, 2019, 11(13): 1598.
- [40] REICHSTEIN M, CAMPS-VALLS G, STEVENS B, et al. Deep learning and process understanding for data-driven Earth system science[J]. *Nature*, 2019, 566(7743): 195-204.
- [41] BUONGIORNO NARDELLI B. A deep learning network to retrieve ocean hydrographic profiles from combined satellite and in situ measurements[J]. *Remote Sensing*, 2020, 12(19): 3151.
- [42] BARTH A, ALVERA AZCÁRATE A, LICER M, et al. A convolutional neural network with error estimates to reconstruct sea surface temperature satellite observations (DINCAE)[C]//EGU General Assembly Conference Abstracts. 2020: 9414.
- [43] UITZ J, CLAUSTRE H, MOREL A, et al. Vertical distribution of phytoplankton communities in open ocean: An assessment based on surface chlorophyll[J]. *Journal of Geophysical Research: Oceans*, 2006, 111(C8).
- [44] CHARANTONIS A A, BADRAN F, THIRIA S. Retrieving the evolution of vertical profiles of Chlorophyll-a from satellite observations using Hidden Markov Models and Self-Organizing Topological Maps[J]. *Remote Sensing of Environment*, 2015, 163: 229-239.
- [45] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural computation*, 1997, 9(8): 1735-1780.
- [46] MASTERS D, LUSCHI C. Revisiting small batch training for deep neural networks[J]. *arXiv preprint arXiv:1804.07612*, 2018.